

RENCANA KERJA TIM (RKT)

Proposal Tugas Besar Analisis Big Data — SDG 10 Reduced Inequalities

A. INFORMASI PROYEK

Judul Proyek	Implementasi Medallion Architecture Berbasis Apache Spark untuk Pemrosesan Data Mikro Sensus Ketimpangan Pendapatan (SDG 10) dengan Dashboard Interaktif Streamlit
Tema	SDG 10 Reduced Inequalities
Dataset	IPUMS International (Brazil 2010, Mexico 2010) estimasi 800.000–1.300.000 baris
Teknologi	Apache Spark 3.5, Docker, Python, PySpark, Streamlit, Delta Lake (opsional)

B. PEMBAGIAN PERAN TIM (5 ANGGOTA)

No	Nama Lengkap	Peran / Role	Tanggung Jawab Utama
1	Ginda Fajar Riadi Marpaung	Ketua / Project Integrator	Koordinasi harian, merge kode, finalisasi proposal & presentasi, integrasi antar-modul, penjadwalan milestone
2	Vany Salsabila Putri	Data Engineer	Handle data IPUMS (download, ekstrak, validasi), bangun Bronze → Silver layer, data quality & profiling
3	Fathya Intami Gusda	Spark Analytics Developer	Bangun Gold layer (Gini UDF, kuintil, Theil index), optimasi query Spark, perhitungan metrik SDG
4	Malika Azzahra	Baseline & Benchmark Specialist	Pipeline Pandas sekuensial, ukur throughput & latensi, bandingkan Spark vs

			Pandas, isi Tabel 2 evaluasi
5	Luthfia Laila Ramadhani	Dashboard & DevOps Engineer	Setup Docker Compose (Spark + Streamlit), bangun dashboard interaktif, diagram arsitektur, Makefile

C. TIMELINE EKSEKUSI 7 HARI

Hari 1 Senin | Tema: Setup Infrastruktur & Data Preparation

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Setup repo GitHub, struktur folder, .gitignore	Ketua	Repo rapi, README.md	Semua anggota clone
09:00–12:00	Setup docker-compose.yml (Spark Master + 2 Worker + Jupyter + Streamlit)	Dashboard & DevOps	docker-compose up jalan, semua service healthy	Cek port 8888, 8080, 8501
13:00–15:00	Download & ekstrak data IPUMS Brazil 2010 + Mexico 2010	Data Engineer	File .csv di /data/raw/	Jika IPUMS belum approved, generate dummy 200rb baris
15:00–17:00	Research paper Liu et al., cari 2–3 referensi tambahan	Ketua	Catatan sitasi + ringkasan paper	Untuk bagian Ringkasan Paper proposal
19:00–21:00	Sync meeting harian (15 menit)	Ketua	Lapor progress & blockers	Via Zoom/Google Meet

Hari 2 Selasa | Tema: Bronze Layer + Baseline Pandas (Paralel)

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Bronze Layer: Ingesti CSV IPUMS → PySpark DataFrame → validasi skema → Parquet	Data Engineer	Script bronze_layer.py, folder /data/bronze/ terisi	Gunakan spark.read.csv() dengan inferSchema
09:00–12:00	Baseline Pandas: Baca CSV → cleaning → hitung Gini exact + kuintil	Baseline	Notebook 01_baseline_pandas.ipynb dengan %timeit	Catat waktu eksekusi & memory usage

13:00–15:00	Draft bagian Dataset & Arsitektur proposal	Ketua	Deskripsi IPUMS + diagram Medallion	Sinkron dengan Data Engineer
15:00–17:00	EDA awal: cek distribusi income, null percentage, outlier	Data Engineer + Baseline	Notebook EDA dengan visualisasi matplotlib	Untuk paham karakteristik data
19:00–21:00	Sync meeting harian	Ketua	Lapor progress & blockers	Pastikan Bronze & Baseline jalan

Hari 3 Rabu | Tema: Silver Layer + Transformasi Data

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Silver Layer: Filter null INCTOT, deduplikasi SERIAL+PERNUM, normalisasi PPP	Data Engineer	Script silver_layer.py, folder /data/silver/	Tambahkan kolom income_ppp_normalized
09:00–12:00	Optimasi partitioning Spark (partitionBy COUNTRY, YEAR)	Spark Dev	Log konfigurasi, cek file size per partisi	Gunakan coalesce/repartition jika perlu
13:00–15:00	Draft bagian Metode Pembanding & Evaluasi	Baseline	Isi proposal	Tabel 2 template siap diisi angka
15:00–17:00	Data quality checks: null percentage per kolom, outlier detection	Data Engineer	Report data quality	Gunakan Great Expectations (opsional) atau manual
19:00–21:00	Sync meeting harian	Ketua	Lapor progress & blockers	Review code via GitHub PR

Hari 4 Kamis | Tema: Gold Layer + Perhitungan Metrik SDG

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Gold Layer: Agregasi kuintil, Gini coefficient (weighted approxQuantile), Palma ratio, Theil index	Spark Dev	Script gold_layer.py, folder /data/gold/	Custom UDF untuk Gini dengan PERWT
13:00–15:00	Validasi akurasi: bandingkan Gini Spark vs Pandas	Baseline + Spark Dev	Selisih error ≤ 0.020 ? Dokumentasi	Jika > 0.020 , debug UDF Spark

15:00–17:00	Draft bagian Ringkasan Paper & Tantangan Etis	Ketua + Dashboard	Isi proposal	Tantangan etis: privasi + bias algoritmik
17:00–19:00	Integration test: Bronze → Silver → Gold end-to-end	Ketua	Pipeline jalan tanpa error	Hapus data, jalankan ulang dari nol
19:00–21:00	Sync meeting harian	Ketua	Lapor progress & blockers	Gold layer harus 100% jalan hari ini

Hari 5 Jumat | Tema: Dashboard Interaktif Streamlit

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Dashboard Streamlit: Baca Parquet Gold → visualisasi Gini & kuintil	Dashboard & DevOps	dashboard.py di localhost:8501	Gunakan st.sidebar untuk filter
09:00–12:00	Fitur wajib: (1) Filter negara, (2) Bar chart Gini, (3) Histogram distribusi income, (4) Tabel kuintil interaktif	Dashboard & DevOps	Screenshot/GIF dashboard jalan	Tambahkan plotly untuk interaktivitas
13:00–15:00	Fitur tambahan: Drill-down per sektor (INDGEN) & okupasi (OCCISCO)	Dashboard & DevOps	Chart tambahan	Box plot income per sektor
15:00–17:00	Integrasi: cek Spark write Gold vs Streamlit read (tidak bentrok)	Dashboard & DevOps	Test concurrency berhasil	Gunakan shared Docker volume
17:00–19:00	Update docker-compose.yml final dengan 5 service	Dashboard & DevOps	File YAML final	Spark Master + 2 Worker + Jupyter + Streamlit
19:00–21:00	Sync meeting harian	Ketua	Lapor progress & blockers	Demo dashboard ke semua anggota

Hari 6 Sabtu | Tema: Benchmarking + Polish Proposal

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–12:00	Benchmark end-to-end: ukur waktu Bronze→Silver→	Baseline	Tabel 2 lengkap dengan angka nyata	Hardware identik: RAM 16GB, 4-core

	Gold vs Pandas monolitik			
09:00–12:00	Grafik speedup: matplotlib/plotly visualisasi perbandingan	Baseline + Spark Dev	Chart throughput & latensi	Sertakan di notebook & dashboard
13:00–15:00	Re-run pipeline dari nol (clean slate), catat waktu per layer	Semua	Video/screenshot	Dokumentasi untuk bukti ke dosen
15:00–17:00	Finalisasi proposal DOCX (semua bagian), cek format IEEE	Ketua	Proposal_Tugas Besar_ABD.docx final	Sinkron dengan semua anggota
17:00–19:00	Buat diagram arsitektur lengkap (Medallion + Docker + Streamlit)	Dashboard & DevOps	Gambar PNG/Slide	Gunakan draw.io atau PowerPoint
19:00–21:00	Sync meeting harian	Ketua	Review semua deliverable	List check apa yang kurang

Hari 7 Minggu | Tema: Testing Final & Submission

Waktu	Tugas	Penanggung Jawab	Deliverable	Keterangan
09:00–11:00	Demo internal: jalankan pipeline + buka dashboard (15 menit)	Semua	Feedback, perbaiki bug minor	Simulasi presentasi ke dosen
11:00–13:00	Final check: sitasi, tabel, gambar, format template dosen	Ketua	Siap print/submit	Cek kelengkapan 3x
13:00–15:00	Buat video demo 60 detik (opsional tapi recommended)	Dashboard & DevOps	File MP4/GIF	Dari docker-compose up sampai dashboard
15:00–17:00	Backup repo + data + proposal ke Google Drive / ZIP	Ketua	File arsip	Jangan lupa exclude data mentah dari ZIP publik
17:00–19:00	Final sync & motivasi tim	Semua	Siap presentasi	Yakin, ini bisa!

D. CHECKLIST DELIVERABLE AKHIR

No	Deliverable	PIC Utama	Status
1	Proposal DOCX lengkap sesuai template dosen	Ketua	☐ Belum ☐ Review ☐ Final
2	Pipeline Medallion jalan (Bronze → Silver → Gold)	Data Engineer + Spark Dev	☐ Belum ☐ Review ☐ Final
3	Dashboard Streamlit interaktif di localhost:8501	Dashboard & DevOps	☐ Belum ☐ Review ☐ Final
4	Tabel benchmark Spark vs Pandas dengan angka nyata	Baseline	☐ Belum ☐ Review ☐ Final
5	Diagram arsitektur lengkap (Medallion + Docker + Streamlit)	Dashboard & DevOps	☐ Belum ☐ Review ☐ Final
6	GitHub repo rapi (tanpa data mentah, hanya kode)	Ketua	☐ Belum ☐ Review ☐ Final
7	Video/GIF demo 60 detik (opsional, nilai tambah)	Dashboard & DevOps	☐ Belum ☐ Review ☐ Final

E. ATURAN KOLABORASI & GIT

1. Branching: main (production), feature/nama-fitur (development). Pull Request wajib direview Ketua sebelum merge.
2. Commit message harus jelas: feat: bronze layer, fix: null handling, docs: update proposal.
3. Data mentah IPUMS (.csv, .gz) TIDAK BOLEH di-push ke GitHub publik (melanggar lisensi). Tambahkan ke .gitignore.
4. Daily sync meeting setiap jam 19:00–21:00 via Google Meet/Zoom (15–30 menit). Laporan progress, blocker, dan rencana besok.
5. Setiap anggota wajib update progress di spreadsheet/shared doc sebelum sync meeting.
6. Jika anggota stuck > 2 jam, segera eskalasi ke grup — jangan diam-diam.
7. Backup harian: push ke GitHub minimal 1x sehari, meski belum selesai.

F. RISK MITIGATION (JIKA ADA MASALAH)

Risiko	Dampak	Solusi
IPUMS belum approved hari ke-5	Tidak ada data asli	Gunakan dummy data 500rb–1jt baris dengan distribusi log-normal mirip

		Brazil/Mexico. Pipeline tetap valid.
Laptop lemot saat Spark	Out-of-memory, crash	Kurangi worker jadi 1, turunkan sample dummy ke 100rb baris, atau naikkan spark.executor.memory.
Gini Spark beda jauh dengan Pandas	Akurasi dipertanyakan	Cek apakah PERWT sudah digunakan di Spark. Jika belum, itu penyebab utama bias.
Docker container tidak connect	Pipeline tidak jalan	Restart Docker Desktop, docker-compose down lalu up, cek port 4040/8888/8501 tidak bentrok.
Anggota sakit/tidak bisa kerja	Tugas tertunda	Backup plan: Ketua atau anggota lain ambil alih task paling kritis. Scope dikurangi jika perlu.