



PROPOSAL TUGAS BESAR ANALISIS BIG DATA Sains Data Institut Teknologi Sumatera 2026

Judul Tugas Besar

Implementasi Medallion Architecture Berbasis Apache Spark untuk Pemrosesan Data Mikro Sensus Ketimpangan Pendapatan (SDG 10): Studi Kasus IPUMS International dengan Kontainerisasi Docker

Identitas Mahasiswa

No	Nama Peran	NIM	Username Github
1	GINDA FAJAR RIADI MARPAUNG	123450103	JARS-17
2	LUTHFIA LAILA RAMADHANI	123450004	Luthfiaarmdhni
3	VANY SALSABILA PUTRI	123450022	vanyysalsabila
4	MALIKA AZZAHRA SALSABILA	123450090	malzhraa
5	FATHYA INTAMI GUSDA	123450095	FathyaIntami

Tema Tugas Besar

SDG 10 - Berkurangnya Kesenjangan

Ringkasan Proposal

Ringkasan proposal (maksimum 300 kata) berisi Urgensi, tujuan, metode, dan luaran yang dihasilkan/targetkan

Ketimpangan pendapatan merupakan indikator krusial dalam Sustainable Development Goal 10 (SDG 10), namun analisisnya menghadapi tantangan besar ketika data mikro sensus mencakup ratusan ribu hingga jutaan baris rekaman individu lintas negara. Proposal ini merancang sistem pemrosesan data skala besar menggunakan Medallion Architecture (Bronze-Silver-Gold) yang diimplementasikan dengan Apache Spark untuk komputasi terdistribusi dan Docker untuk kontainerisasi infrastruktur. Dataset IPUMS International yang berisi data mikro sensus dari lebih dari 90 negara digunakan sebagai studi kasus, dengan subset ekstraksi mencakup minimal 150.000 baris data demografi, ketenagakerjaan, dan pendapatan rumah tangga. Tujuan utama adalah mengukur efisiensi arsitektur ini dalam memproses dan mengagregasi data ketimpangan dibandingkan dengan metode sekuensial konvensional. Luaran yang ditargetkan meliputi pipeline ETL terdistribusi yang terkontainerisasi, tabel analitik Gini coefficient dan shared prosperity premium di lapisan Gold, serta perbandingan metrik throughput dan latensi yang menunjukkan skalabilitas sistem terdistribusi terhadap pendekatan tradisional.

Kata kunci

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

SDG 10; Medallion Architecture; Apache Spark; Docker; Data Lakehouse

Substansi Usulan

Petunjuk: Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan (diberi warna) sesuai dengan petunjuk pengisian dan tidak diperkenankan untuk memodifikasi template menghapus setiap bagian.

A. RINGKASAN PAPER

Pilih satu paper yang paling relevan dengan proyek Anda dan tuliskan ringkasannya disini. Jangan melebihi 2 halaman untuk bagian ini.

Tabel 1. Rincian Paper yang diulas

Judul	A big data approach to assess progress towards Sustainable Development Goals for cities of varying sizes
Penulis	Y. Liu et al.
Jurnal	Communications Earth & Environment (Nature Portfolio)
Tahun	2023
URL	https://www.nature.com/articles/s43247-023-00730-8

1. LATAR BELAKANG

Gambarkan konteks paper: apa motivasi dan masalah yang dikemukakan para penulis? Masalah apa yang ingin mereka selesaikan atau pengetahuan apa yang ingin mereka temukan?

Paper ini berangkat dari kenyataan bahwa monitoring SDGs di level kota memerlukan integrasi multisumber data berskala besar (multi source big data) yang memiliki karakteristik volume tinggi, kecepatan generasi tinggi, dan variasi format. Para penulis mengidentifikasi bahwa sebagian besar studi existing hanya menilai satu atau beberapa indikator spesifik dari satu SDG tertentu, tanpa mempertimbangkan evaluasi komprehensif antar-SDG secara simultan. Khusus untuk SDG 10 (Reduced Inequalities), paper ini menyoroti bahwa kota-kota besar di China menghadapi tantangan serius dalam mengurangi ketimpangan pendapatan, meskipun performa SDG lain relatif baik. Motivasi utama penulis adalah mengembangkan kerangka kerja berbasis Artificial Neural Network (ANN) dan data besar (misalnya nighttime light imagery, POI, OpenStreetMap) untuk menilai performa SDG secara menyeluruh dengan biaya rendah dan efisien secara temporal.

2. RINGKASAN KONTRIBUSI

Setiap paper memberikan sesuatu yang baru. Uraikan kontribusi utamanya - algoritma baru, hasil eksperimen, dataset baru, atau analisis baru

Kontribusi utama paper ini meliputi:

- (1) pengembangan model ANN untuk integrasi multi source big data guna menilai performa 17 SDG di level kota;
- (2) konstruksi indikator monitoring berbasis data non-tradisional (seperti citra satelit malam hari untuk estimasi ketimpangan) yang dapat mengisi gap data survei konvensional;
- (3) analisis komparatif performa SDG berdasarkan ukuran kota (besar, menengah, kecil) dan lokasi geografis, yang mengungkapkan bahwa kota kecil—terutama di wilayah barat—memiliki skor SDG Index lebih rendah dan ketimpangan yang lebih tinggi; serta

(4) fondasi metodologis untuk perluasan evaluasi SDG ke negara-negara berkembang lain dengan keterbatasan kapasitas statistik.

3. KETERBATASAN DAN DISKUSI

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis.
Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Keterbatasan metodologis yang diidentifikasi meliputi:

- (a) ketergantungan pada data statistik agregat yang tidak sepenuhnya mencerminkan interaksi antar-SDG di level mikro;
- (b) kurangnya kuantifikasi trade-offs dan synergies antar indikator SDG dalam model ANN;
- (c) keterbatasan cakupan data big data tertentu (misalnya citra satelit) yang tidak selalu tersedia dengan kualitas konsisten untuk semua wilayah, terutama negara berkembang dengan infrastruktur data lemah; dan
- (d) black-box nature model ANN yang membatasi interpretabilitas kebijakan. Keterbatasan ini mengubah cara menilai temuan karena hasil prediksi ketimpangan berbasis citra satelit perlu divalidasi dengan data survei mikro ground-truth sebelum digunakan untuk perumusan kebijakan fiskal.

4. MENGAPA PAPER INI?

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis.
Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Paper ini dipilih karena secara eksplisit menghubungkan big data analytics dengan pengukuran SDG 10 di level sub-nasional, yang relevan langsung dengan fokus proyek kami pada ketimpangan pendapatan. Selain itu, paper ini mengidentifikasi gap literatur yang kami coba jawab secara teknis: sementara Liu et al. berfokus pada inferensi statistik dan machine learning, proyek kami mengisi celah arsitektural dengan merancang pipeline data engineering (Medallion + Spark) yang mampu menangani volume data mikro sensus yang jauh lebih besar daripada data agregat yang mereka gunakan. Setelah membacanya, kami memperoleh pemahaman bahwa infrastruktur data yang scalable merupakan prasyarat tersedianya analitik SDG yang real-time dan berkelanjutan.

5. KONTEKS RISET YANG LEBIH LUAS

Hubungkan paper ini dengan tema-tema besar dalam Big Data: pemrosesan terdistribusi, manajemen kualitas data, skalabilitas, analitik real-time vs. batch, atau kesiapan data untuk machine learning. Apakah metode ini berpotensi diterapkan ke domain lain?

Paper ini berada dalam arus riset big data for sustainable development yang menekankan pemrosesan terdistribusi dan integrasi multi sumber data. Secara tematik, paper ini berinteraksi dengan manajemen kualitas data (harmonisasi variabel lintas negara), skalabilitas analitik (penggunaan ANN untuk dataset besar), dan kesiapan data untuk machine learning (feature engineering dari data mentah menjadi indikator SDG). Metode evaluasi kota berbasis data besar yang diusulkan berpotensi diterapkan ke domain lain seperti pemantauan ketimpangan gender (SDG 5) atau pemetaan kemiskinan ekstrem (SDG 1) dengan mengganti sumber data input sesuai konteks, namun memerlukan arsitektur data yang mampu menangani heterogenitas format dan skala—yang menjadi fokus implementasi teknis proyek kami.

B. DESKRIPSI PROYEK

1. TUJUAN UTAMA

Rumuskan tujuan proyek Anda, idealnya sebagai pertanyaan ilmiah. Contoh: “Apakah arsitektur Medallion berbasis Spark dapat meningkatkan throughput pemrosesan data ekspor dibandingkan pipeline tradisional?” Jelaskan mengapa tujuan ini penting dan memungkinkan dicapai. Sebutkan tujuan sekunder (stretch goal) jika ada, dan hubungkan dengan paper yang Anda pilih.

Pertanyaan ilmiah: “Apakah arsitektur Medallion berbasis Apache Spark yang terkontainerisasi dengan Docker mampu meningkatkan throughput pemrosesan dan mengurangi latensi end-to-end pipeline untuk data mikro sensus ketimpangan pendapatan (SDG 10) dibandingkan dengan pipeline pemrosesan sekuensial berbasis Pandas?”

Tujuan ini penting karena analisis ketimpangan memerlukan agregasi kompleks (kuintil, Gini coefficient, shared prosperity premium) pada dataset dengan ratusan ribu baris rekaman individu. Tujuan sekunder (stretch goal) adalah mengimplementasikan lapisan Gold yang menghasilkan tabel siap-query untuk estimasi indeks Gini nasional dan Theil index secara otomatis, yang terhubung dengan konteks paper Liu et al. mengenai kebutuhan data low-cost untuk monitoring SDG.

2. STUDI KASUS / DOMAIN APLIKASI

Domain apa yang menjadi fokus proyek Anda? Berikan contoh konkret: apa input datanya dan apa output analitik yang diharapkan? Jika sudah dijelaskan dalam ringkasan paper, maka buat lebih detail disini.

Domain aplikasi adalah analisis ketimpangan pendapatan lintas negara berkembang berdasarkan data mikro sensus.

Input data: File CSV mentah hasil ekstraksi IPUMS International yang berisi variabel demografi (usia, jenis kelamin, pendidikan), ketenagakerjaan (status pekerjaan, sektor industri), dan pendapatan rumah tangga (individual earnings, household income) dari Brazil 2010 dan Mexico 2010 untuk total minimal 150.000 baris rekaman individu.

Output analitik: Tabel agregat di lapisan Gold berupa (1) distribusi pendapatan per kuintil per negara, (2) estimasi Gini coefficient nasional, (3) proporsi populasi di bawah 50% median pendapatan (Indikator 10.2.1 SDG), dan (4) shared prosperity premium (pertumbuhan pendapatan bottom 40% vs rata-rata nasional). Output disimpan dalam format Parquet terkompresi yang dapat di-query via Spark SQL.

3. DATASET

Sebutkan dataset yang akan digunakan (sumber, ukuran, format). Jelaskan prapemrosesan yang direncanakan. Jika mengumpulkan data sendiri, jelaskan caranya dan estimasi waktu yang diperlukan.

Dataset yang digunakan adalah IPUMS International (Integrated Public Use Microdata Series, Internasional) yang dikelola oleh Minnesota Population Center. Dataset ini merupakan arsip data mikro sensus publik terbesar di dunia, mencakup 94 negara dari 365 sensus dengan total miliaran baris data individu. Untuk proyek ini, diekstrak subset harmonisasi variabel pendapatan, demografi, dan ketenagakerjaan dari Brazil 2010 dan Mexico 2010 dengan total minimum 150.000 baris (records) dan estimasi ukuran file CSV mentah sekitar 1.2–2.5 GB (tergantung jumlah variabel).

Format dan evolusi penyimpanan:

- Raw/Bronze: CSV terkompresi gzip (1.2 – 2.5 GB)
- Silver: Parquet hasil pembersihan, deduplikasi, dan harmonisasi skala pendapatan ke PPP 2017 International Dollars.
- Gold: Parquet teragregat per negara-periode dengan metrik Gini dan kuintil ($\approx$ 5–10 MB).

Prapemrosesan per layer Medallion:

- Bronze: Ingesti file CSV ke data lake (volume Docker), konversi ke PySpark DataFrame, penanganan missing values dengan flagging, dan validasi skema.
- Silver: Pembersihan outlier pendapatan, harmonisasi kode pendidikan lintas negara, normalisasi mata uang ke PPP, deduplikasi berdasarkan kombinasi SAMPLE-SERIAL-PERNUM, dan pembuatan fitur turunan (misal: equivalized household income).
- Gold: Agregasi per kuintil, perhitungan Gini coefficient menggunakan metode approximate percentile Spark SQL, estimasi shared prosperity premium, dan materialisasi tabel fact siap analisis.

4. ARSITEKTUR DAN TEKNOLOGI

Jelaskan komponen teknis utama yang akan digunakan dan bagaimana mereka berinteraksi. Jika menggunakan Medallion Architecture, jelaskan setiap lapisannya. Tunjukkan mana yang diimplementasikan sendiri dan mana yang menggunakan konfigurasi yang sudah ada.

Proyek mengimplementasikan Medallion Architecture dalam ekosistem containerized:

1. Lapisan Bronze (Raw Ingestion)

Data mikro sensus IPUMS dalam format CSV diunggah ke volume persistent Docker. Apache Spark (mode local cluster dengan 1 Master + 2 Worker containers) membaca file CSV melalui `SparkSession.read.csv()` dengan inferensi skema otomatis. Output disimpan sebagai Delta Lake atau Parquet terpartisi per negara di direktori `/bronze`.

2. Lapisan Silver (Clean & Transform)

Spark mengeksekusi transformation job menggunakan PySpark API: filter invalid records, imputasi nilai hilang, konversi mata uang lokal ke PPP, dan standarisasi kategori variabel demografi. Data hasil transformasi disimpan sebagai Parquet terkompresi snappy di `/silver` dengan partisi per negara dan tahun sensus.

3. Lapisan Gold (Aggregated Analytics)

Spark SQL menjalankan query agregasi untuk menghasilkan metrik ketimpangan: Gini coefficient (menggunakan relative mean absolute difference approximation), Palma ratio, dan proporsi bottom 40%. Hasil disimpan sebagai tabel Parquet kecil yang dioptimalkan untuk random access dan visualisasi.

Interaksi Komponen:

- Docker Compose mengorkestrasi 4 layanan: (a) Spark Master, (b) Spark Worker-1, (c) Spark Worker-2, (d) Jupyter Notebook sebagai driver untuk submit job.
- Apache Spark bertanggung jawab atas pemrosesan paralel dengan partitioning berbasis hash pada kolom COUNTRY dan YEAR, memungkinkan distribusi komputasi 150.000+ baris ke worker nodes.
- Docker Volume digunakan untuk persistent storage antar-container, memastikan data tidak

hilang saat container direstart.

Komponen utama: Apache Spark 3.5, Docker & Docker Compose, Python 3.11, PySpark, JupyterLab, Delta Lake (opsional).

Diimplementasikan sendiri: Kode ETL PySpark untuk transformasi antar-layer, perhitungan metrik Gini custom UDF, dan docker-compose.yml.

Menggunakan konfigurasi yang tersedia: Image Docker resmi bitnami/spark:latest dan jupyter/pyspark-notebook.

5. METODE PEMBANDING (BASELINE)

Metode apa yang digunakan sebagai pembanding? Misalnya: pemrosesan sekuensial tanpa distribusi, pipeline sederhana satu lapisan, atau implementasi yang telah dipublikasikan. Jelaskan apakah diimplementasikan sendiri atau diambil dari sumber lain.

Metode pembanding adalah pipeline sekuensial berbasis Python Pandas yang diimplementasikan sendiri dalam satu Jupyter Notebook tanpa kontainerisasi maupun distribusi. Pipeline ini menjalankan operasi identik (read CSV → clean → groupby → aggregate Gini) secara monolitik pada single-threaded Python. Metode ini dipilih karena merepresentasikan pendekatan konvensional yang umum digunakan oleh data scientist/analyst untuk dataset berukuran medium sebelum menghadapi kendala memori (out-of-memory) dan waktu proses pada skala besar.

6. EVALUASI

Tentukan minimal satu metrik kuantitatif yang jelas. Contoh metrik yang umum digunakan: throughput (baris/detik), latensi end-to-end pipeline, akurasi prediksi (RMSE/MAE untuk regresi, silhouette score untuk clustering), atau rasio kompresi penyimpanan. Sebutkan nilai acuan (baseline score) yang ada di literatur atau yang Anda targetkan.

Tabel 2. Metrik evaluasi yang direncanakan

Metrik	Acuan (Baseline)	Target
Throughput ingesti (baris/dtk)	2.500 (Pandas sekuensial, single-node)	≥ 25.000 (Spark distributed, 3-node Docker)
Latensi pipeline end-to-end (Bronze → Gold)	18 menit (Pandas, in-memory)	≤ 4 menit (Spark, dengan spill ke disk jika perlu)
Rasio kompresi storage (CSV vs Parquet)	1.0 (baseline CSV)	≥ 3.0x (Parquet + Snappy)
Akurasi estimasi Gini coefficient	±0.015 (Pandas exact)	±0.020 (Spark approximate, acceptable)

Baseline diukur pada hardware identik (laptop/VM dengan RAM 16 GB, 4-core CPU) untuk memastikan perbandingan adil antara single-node vs pseudo-cluster Docker lokal.

7. TANTANGAN ETIS DAN RISIKO SOSIAL

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang memengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

Proyek ini menghadapi dua tantangan etis utama yang spesifik pada domain data sensus dan ketimpangan.

1. Tantangan Pertama

Risiko privasi dan re-identifikasi data mikro. Meskipun IPUMS International telah menerapkan statistical disclosure control (penyamaran dan sampling), penggabungan dataset lintas negara dengan variabel demografi detail (usia, jenis kelamin, lokasi geografis, pekerjaan) berpotensi meningkatkan risiko microdata re-identification jika dianalisis bersama sumber data eksternal. Mitigasi yang dilakukan meliputi: (a) hanya menggunakan variabel yang telah di-harmonisasi dan dikodekan oleh IPUMS tanpa informasi direct identifier; (b) tidak mengunggah data mentah ke repositori publik, melainkan hanya menyediakan skema pipeline dan hasil agregat lapisan Gold; serta (c) menerapkan differential privacy sederhana pada output Gini per sub-regional dengan menambahkan Laplace noise jika diperlukan.

2. Tantangan Kedua

Risiko bias algoritmik dalam agregasi ketimpangan. Pipeline Spark yang mengimplementasikan perhitungan kuintil dan Gini secara terdistribusi menggunakan approximate percentile dapat memperkenalkan bias sistematis terhadap kelompok rentan jika sampling weights (PERWT) tidak ditangani dengan benar. Di banyak negara berkembang, populasi miskin dan perempuan seringkali underrepresented dalam sensus, sehingga agregasi yang tidak memperhitungkan sampling weights akan menghasilkan estimasi ketimpangan yang mendiskriminasi kelompok rentan dan berpotensi salah menginformasikan kebijakan fiskal. Mitigasi praktis yang dirancang adalah:

- (a) memastikan variabel PERWT (person weight) diterapkan dalam semua operasi agregasi Spark menggunakan weighted approxQuantile;
- (b) melakukan sensitivity analysis dengan membandingkan hasil Gini berbobot vs tidak berbobot; dan
- (c) mendokumentasikan asumsi data dan keterbatasan representativitas dalam setiap lapisan Gold untuk transparansi terhadap pengambil kebijakan.

REFERENSI

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang memengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

[1] Y. Liu et al., "A big data approach to assess progress towards Sustainable Development Goals for cities of varying sizes," Communications Earth & Environment, vol. 4, no. 1, p. 82, 2023. [Online]. Available: <https://www.nature.com/articles/s43247-023-00730-8>

- [2] Minnesota Population Center, Integrated Public Use Microdata Series, International: Version 7.2 [dataset], Minneapolis, MN: IPUMS, 2019. <https://doi.org/10.18128/D020.V7.2>
- [3] World Bank, Atlas of Sustainable Development Goals 2020: From World Development Indicators, Washington, DC: World Bank, 2020.
<https://datatopics.worldbank.org/sdgatlas/archive/2020/goal-10-reduced-inequalities/>
- [4] M. Armbrust et al., "Delta Lake: High-Performance ACID Table Storage over Cloud Object Stores," Proceedings of the VLDB Endowment, vol. 13, no. 12, pp. 3411–3424, 2020.
- [5] LIS Cross-National Data Center in Luxembourg, Luxembourg Income Study Database: Inequality and Poverty Key Figures, 1967-2020 [Data Collection], Colchester, Essex: UK Data Service, 2022.
<https://doi.org/10.5255/UKDA-SN-855648>